

Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

**Отчет
по учебно-исследовательской работе 1**

**Обработка результатов измерений
Статистический анализ числовой последовательности**

Дисциплина «Моделирование»

Вариант: 26

Выполнил:

студент 1 курса

Тимошкин Роман Вячеславович

Группа: Р3330

Принял: Бессмертный Игорь Александрович

Отчет принят «___» _____ 20__ г.

Оценка: ____

Задание и методика расчета

Цель работы — изучить методы обработки результатов измерений, оценить числовые характеристики заданной последовательности, исследовать ее корреляционные свойства и аппроксимировать распределение по двум начальным моментам.

Исходные данные: 300 значений из variant.md в исходном порядке. Исследуются первые $n = 10, 20, 50, 100, 200$ и 300 наблюдений. Номер варианта в исходном файле не указан. Все расчеты выполнены программно на Python.

Работа включает расчет характеристик и доверительных интервалов, анализ графика и автокорреляции, построение гистограммы, выбор закона распределения, генерацию новой последовательности и сравнение результатов.

Расчетные формулы

Среднее: $m_n = (1/n) \sum x_i$.

Исправленная дисперсия: $s_n^2 = \sum (x_i - m_n)^2 / (n - 1)$.

Среднеквадратическое отклонение: $s_n = \sqrt{s_n^2}$; коэффициент вариации: $V_n = s_n/m_n$.

Начальные моменты: $a_1 = (1/n) \sum x_i$; $a_2 = (1/n) \sum x_i^2$.

Доверительный интервал: $m_n \pm h\gamma$; $h\gamma = t((1 + \gamma)/2; n - 1) \cdot s_n/\sqrt{n}$.

Относительное отклонение: $\delta = 100 \cdot (\theta_n - \theta_{эт})/\theta_{эт}$.

В форме 1 эталон — характеристика исходной выборки при $n = 300$. В форме 2 используется тот же эталон исходной выборки, как в примере отчета. Дополнительно характеристики при $n = 300$ сравниваются напрямую.

Интервалы Стьюдента точны для независимых нормальных наблюдений. Здесь распределение асимметрично, поэтому интервалы используются как приближение, особенно осторожно при $n = 10$ и 20. В таблицах указывается полуинтервал $\pm h\gamma$, а не его полная ширина.

Итог выбора модели: $V_{300} > 1$, поэтому применяется гиперэкспоненциальное распределение второго порядка H2 с точным согласованием среднего и выбранной оценки дисперсии.

Этап 1 Числовые характеристики исходной последовательности

Таблица 1 — Характеристики заданной последовательности по форме 1

Показатель	Вид	10	20	50	100	200	300
Мат. ожидание	Знач.	4,058	7,909	10,327	13,754	11,511	11,996
	%	-66,17	-34,07	-13,91	14,66	-4,04	0,00
ДИ 0,90	Знач.	±2,194	±5,371	±4,470	±5,237	±3,009	±2,667
	%	-17,72	101,40	67,61	96,39	12,85	0,00
ДИ 0,95	Знач.	±2,708	±6,501	±5,357	±6,258	±3,591	±3,181
	%	-14,87	104,39	68,44	96,78	12,90	0,00
ДИ 0,99	Знач.	±3,890	±8,886	±7,145	±8,284	±4,736	±4,190
	%	-7,16	112,09	70,53	97,72	13,03	0,00
Дисперсия	Знач.	14,326	192,935	355,356	994,852	663,159	783,602
	%	-98,17	-75,38	-54,65	26,96	-15,37	0,00
СКО	Знач.	3,785	13,890	18,851	31,541	25,752	27,993
	%	-86,48	-50,38	-32,66	12,68	-8,01	0,00
Коэф. вариации	Знач.	0,933	1,756	1,825	2,293	2,237	2,334
	%	-60,03	-24,74	-21,77	-1,73	-4,13	0,00

Значения округлены только при выводе. Дисперсия рассчитана с делителем $n - 1$; для ДИ в строках процентов сравниваются полуинтервалы.

Для полной выборки: $m = 11,995543$, $s^2 = 783,602090$, $s = 27,992894$, $V = 2,333608$. Минимум 0,009, максимум 280,938.

ДИ 0.90: [9,329; 14,662].

ДИ 0.95: [8,815; 15,176].

ДИ 0.99: [7,806; 16,185].

Вывод. Малые выборки существенно недооценивают среднее и разброс. Большие редкие значения сильно влияют на дисперсию, поэтому рост объема выборки не обеспечивает монотонного приближения каждой оценки к эталону. $V > 1$ указывает на разброс, превышающий среднее.

Этап 2 Анализ графика значений




График 1 — Значения исходной числовой последовательности

На графике видны редкие большие значения на фоне большинства малых наблюдений. Наибольшее значение 280,938 соответствует наблюдению № 256. Последовательность не является монотонно возрастающей или убывающей.

Линейный тренд имеет наклон 0,002185 на одно наблюдение; корреляция значения с номером наблюдения равна 0,006770. Значимость наклона $p = 0,9070$, поэтому линейный тренд по этим данным не выявлен.

Повторяющегося рисунка всплесков и устойчивого периода по графику не обнаружено. Проверка автокорреляции на следующем этапе дополняет визуальный анализ.

Вывод. Наблюдается нерегулярная последовательность с сильными одиночными всплесками и без явного тренда или периодичности. Это согласуется со случайным характером, но один график не доказывает независимость наблюдений.


Этап 3 Автокорреляционный анализ

Для каждого k рассчитывается коэффициент Пирсона между векторами $(x_1, \dots, x_{n-k})$ и $(x_{1+k}, \dots, x_n)$. Средние и нормы вычисляются отдельно по двум сдвинутым векторам. Для новой последовательности используется та же формула.

Таблица 2 — Коэффициенты автокорреляции по форме 3

Сдвиг k	1	2	3	4	5	6	7	8
Исходная	0,0414	-0,0412	-0,0257	0,0084	-0,0486	0,0944	-0,0481	0,0196
Сгенерир.	0,0363	0,0015	0,0162	-0,0590	0,0066	-0,0447	0,0401	0,0059
$\delta, \%$	-12,2	-103,6	-163,0	-800,7	-113,5	-147,4	-183,4	-69,8
Сдвиг k	9	10	11	12	13	14	15	
Исходная	0,0270	0,0260	-0,0692	-0,0760	-0,0123	-0,0474	-0,0616	
Сгенерир.	-0,0024	0,0654	0,0907	0,0482	-0,0236	0,0718	0,1001	
$\delta, \%$	-108,8	151,6	-231,0	-163,4	91,7	-251,7	-262,5	

$\delta = 100(r_y - r_x)/r_x$. При r_x около нуля эта величина неустойчива и не является мерой качества аппроксимации.



Ориентировочные границы при отсутствии корреляции: $\pm 1,96/\sqrt{300} = \pm 0,1132$. Максимум $|r_x(k)| = 0,0944$; максимум $|r_y(k)| = 0,1001$.

Вывод. На сдвигах 1–15 значимых отклонений от нуля по указанным приближенным границам не выявлено у обеих последовательностей. Данные согласуются с отсутствием линейной серийной зависимости; это не доказывает полной независимости.

Этап 4 Гистограмма распределения частот

Использованы 10 равных интервалов шириной 29 на диапазоне $[0; 290]$. Выбор числа интервалов близок к правилу Стерджеса: $1 + \log_2 300 \approx 9,23$. Все наблюдения попадают в выбранный диапазон.




График 2 — Гистограмма исходной последовательности

Интервал	Частота	Относительная частота
[0; 29)	268	0,8933
[29; 58)	19	0,0633
[58; 87)	5	0,0167
[87; 116)	4	0,0133
[116; 145)	1	0,0033
[145; 174)	0	0,0000
[174; 203)	2	0,0067
[203; 232)	0	0,0000
[232; 261)	0	0,0000
[261; 290]	1	0,0033

Вывод. Распределение резко асимметрично вправо: в первом интервале находятся 268 из 300 значений (89,33%). Редкие большие значения образуют длинный правый хвост. В сочетании с $V = 2,334$ это обосновывает выбор гиперэкспоненциальной модели.

Этап 5 Выбор и параметры закона распределения

Два начальных момента: $a_1 = 11,995543$, $a_2 = 924,883143$. Их центральный момент $a_2 - a_1^2 = 780,990083$. Для согласования с таблицами применяется исправленная оценка $s^2 = n/(n - 1) \cdot (a_2 - a_1^2) = 783,602090$.

H2 — смесь двух экспоненциальных распределений. С вероятностью p выбирается ветвь с интенсивностью λ_1 , с вероятностью $1 - p$ — ветвь с интенсивностью λ_2 . Два момента не определяют три параметра однозначно, поэтому используется дополнительное условие равного вклада ветвей в среднее: $p/\lambda_1 = (1 - p)/\lambda_2 = m/2$.

$f(t) = p\lambda_1 \exp(-\lambda_1 t) + (1 - p)\lambda_2 \exp(-\lambda_2 t)$, $t \geq 0$; $f(t) = 0$ при $t < 0$.

$E[T] = p/\lambda_1 + (1 - p)/\lambda_2$.

$E[T^2] = 2p/\lambda_1^2 + 2(1 - p)/\lambda_2^2$.

$p = \frac{1}{2}[1 + \sqrt{((V^2 - 1)/(V^2 + 1))}]$; $\lambda_1 = 2p/m$; $\lambda_2 = 2(1 - p)/m$.

Параметр	Значение
V^2	5,445725392
p	0,915245965
$1 - p$	0,084754035
λ_1	0,152597667
λ_2	0,014130921
$1/\lambda_1$	6,553180
$1/\lambda_2$	70,766798

Проверка: $E[T] = 11,995543$; $\text{Var}[T] = 783,602090$; $E[T^2] = 927,495150$. Разница $E[T^2]$ и эмпирического a_2 равна поправке на несмещенность дисперсии $s^2 - (a_2 - a_1^2) = 2,612007$.

Вывод. H2 воспроизводит среднее и исправленную дисперсию без округления порядка распределения. Быстрая ветвь описывает основную массу малых значений, медленная — редкие большие значения. Совпадение двух моментов само по себе не гарантирует совпадения всей формы распределения.

Этап 6 Алгоритм генерации последовательности

Реализация приложена в `generator.py`. Используются NumPy и SciPy; генератор NumPy `default_rng` с фиксированным `seed = 2026` обеспечивает воспроизводимость. Объем новой выборки — 300 наблюдений. Начальное состояние не подбиралось по совпадению результатов.

1. Прочитать исходную выборку и вычислить m , s^2 , V^2 .
2. Рассчитать p , λ_1 и λ_2 по формулам этапа 5.
3. Сформировать два независимых массива U и W из 300 значений равномерного распределения на $[0; 1)$.
4. Для $i = 1, \dots, 300$ выбрать $\lambda_i = \lambda_1$ при $U_i < p$ и $\lambda_i = \lambda_2$ иначе.
5. Вычислить $Y_i = -\ln(1 - W_i)/\lambda_i$. Это обратное преобразование функции распределения выбранной экспоненциальной ветви.
6. Для первых 10, 20, 50, 100, 200, 300 значений вычислить характеристики, ДИ и относительные отклонения. Сохранить обе последовательности и таблицу характеристик в CSV.

Ключевой фрагмент программы

```
rng = np.random.default_rng(2026)
u = rng.random(300)
w = rng.random(300)
lam = np.where(u < p, lambda1, lambda2)
y = -np.log1p(-w) / lam
```

Порядок демонстрации на защите: установить `numpy` и `scipy`, распаковать архив и выполнить `python generator.py`. Программа использует `source_sequence.csv`; можно также передать путь к `variant.md`. На экран выводятся параметры, взаимная корреляция и автокорреляции, создаются `sequences.csv` и `characteristics.csv`.

Первое значение $Y_1 = 8,890531$, последнее $Y_{300} = 0,451369$. Полученная выборка сохранена с точностью 12 знаков после десятичной точки.

Вывод. Генератор формирует именно смесь экспоненциальных распределений: для одного наблюдения выбирается одна ветвь. Использование фиксированного начального состояния позволяет повторить все приведенные расчеты.

Этап 7 Характеристики сгенерированной последовательности

Таблица 3 — Характеристики сгенерированной последовательности по форме 2. Закон распределения Н2

Показатель	Вид	10	20	50	100	200	300
Мат. ожидание	Знач.	3,363	11,050	9,974	11,704	10,255	13,916
	%	-71,96	-7,88	-16,85	-2,43	-14,51	16,01
ДИ 0,90	Знач.	±1,537	±11,008	±4,419	±3,590	±2,278	±2,988
	%	-42,35	312,80	65,72	34,62	-14,59	12,06
ДИ 0,95	Знач.	±1,897	±13,325	±5,297	±4,290	±2,718	±3,564
	%	-40,36	318,94	66,55	34,88	-14,55	12,06
ДИ 0,99	Знач.	±2,725	±18,213	±7,064	±5,678	±3,584	±4,695
	%	-34,95	334,71	68,60	35,53	-14,45	12,06
Дисперсия	Знач.	7,032	810,560	347,393	467,410	379,888	983,940
	%	-99,10	3,44	-55,67	-40,35	-51,52	25,57
СКО	Знач.	2,652	28,470	18,638	21,620	19,491	31,368
	%	-90,53	1,71	-33,42	-22,77	-30,37	12,06
Коэф. вариации	Знач.	0,788	2,576	1,869	1,847	1,901	2,254
	%	-66,21	10,41	-19,92	-20,84	-18,56	-3,41

Проценты рассчитаны относительно одноименных характеристик исходной выборки из 300 наблюдений. Для сравнения при одинаковых объемах n полные данные обеих выборок включены в приложенный файл `characteristics.csv`.

При $n = 300$ среднее новой выборки 13,916 отличается на 16,01%; дисперсия 983,940 — на 25,57%; СКО — на 12,06%; коэффициент вариации — на -3,41%.

Вывод. Теоретические моменты модели совпадают с выбранными оценками исходной выборки, однако моменты конкретной реализации отличаются. При тяжелом правом хвосте редкие большие значения существенно меняют оценки даже при $n = 300$. Отличия одной реализации не следует смешивать с ошибкой согласования параметров модели.

Этап 7 Сравнение распределений и взаимной корреляции




График 3 — Плотность модели H2 и нормированная гистограмма исходных данных

Для сопоставления с плотностью высоты столбцов равны $n_i/(300 \cdot \Delta_i)$. На увеличенном фрагменте нормировка также выполнена по всем 300 значениям; это не условная плотность в диапазоне $[0; 30]$. Модель передает высокую концентрацию малых значений и длинный правый хвост. Различия внутри интервалов сохраняются.




График 4 — Сравнение значений и гистограмм двух последовательностей

Коэффициент Пирсона между X и Y: $r = -0,062740$. Приближенная проверка: $t = -1,0852$, $p = 0,2787$. По уровню 0,05 значимая линейная связь не выявлена. Из-за асимметрии распределений p следует считать ориентировочным.

Вывод. Новая выборка воспроизводит общий вид распределения, но не порядок всплесков исходной последовательности. Низкая взаимная корреляция ожидаема для новой случайной реализации и не является самостоятельным доказательством качества модели.

Выводы по работе

1. Обработаны все 300 исходных значений и шесть вложенных выборок. Для полной выборки получены $m = 11,996$, $s^2 = 783,602$, $s = 27,993$, $V = 2,334$. Рассчитаны доверительные полуинтервалы для вероятностей 0,90, 0,95 и 0,99, а также относительные отклонения от эталона.
2. График не показывает монотонности или устойчивой периодичности. Автокорреляции на сдвигах 1–15 согласуются с отсутствием линейной серийной зависимости. По проведенным проверкам исходную последовательность допустимо рассматривать как случайную; независимость этими проверками не доказана.
3. Гистограмма имеет выраженную правую асимметрию. Для $V > 1$ выбрана гиперэкспоненциальная модель H2. При дополнительном условии равного вклада двух ветвей в среднее модель точно воспроизводит m и исправленную дисперсию s^2 .
4. Программно сгенерированы 300 значений H2. При $\text{seed} = 2026$ среднее составляет 13,916, дисперсия — 983,940. Их отклонения от исходных оценок равны соответственно 16,01% и 25,57%. Это характеризует конкретную конечную реализацию, а не несовпадение теоретических моментов.
5. Автокорреляционный анализ новой выборки не выявил значимых линейных зависимостей на рассмотренных сдвигах. Взаимная корреляция двух последовательностей $r = -0,062740$ мала по абсолютной величине.
6. Качество аппроксимации оценено по согласованию моментов и графическому сравнению плотности с гистограммой. Модель передает основную концентрацию наблюдений и правый хвост. Строгий критерий согласия не выполнялся, поэтому утверждение о точном распределении исходных данных как H2 не делается. Для более устойчивого сравнения эмпирических моментов полезны более длинные реализации или несколько независимых повторов.